



UNIVERSIDAD
NACIONAL AUTÓNOMA
DE MÉXICO
FACULTAD DE CIENCIAS



Almacenes y Minería de Datos

Análisis del Comercio Exterior de México: Predicción del Balance Comercial y Segmentación de Socios Comerciales

Proyecto Final

Integrante 1: Solano Marcial Irany

No. de cuenta: 304229066

Integrante 2: Jiménez Ruíz Brenda

No. de cuenta: 423085437

Profesora: Jessica Santizo Galicia

Ayudante de Teoría: Diego Antonio Villalba González

Ayudante de Lab.: Ares Gael Castro Romero

Ciudad de México, junio de 2026



Índice

1. Introducción	3
1.1. ¿Cuál es el problema?	3
1.2. ¿Por qué es relevante?	3
1.3. ¿Qué se busca lograr?	4
1.4. ¿Por qué este dataset?	4
2. Descripción del Dataset	4
2.1. Dimensiones y fuente	4
2.2. Descripción de variables	5
2.3. Limitaciones conocidas	5
3. Limpieza y Preparación de Datos	5
3.1. Valores faltantes	5
3.2. Registros duplicados	6
3.3. Valores atípicos	6
3.4. Variables derivadas y enriquecimiento	6
4. Análisis Exploratorio de Datos	7
4.1. Descripción general	7
4.2. Distribución de variables numéricas	8
4.3. Serie de tiempo 1993–2025	9
5. Modelo Supervisado	9
5.1. Definición de la variable objetivo	10
5.2. Variables de entrada	10
5.3. División de datos	10
5.4. Modelo 1: Random Forest	10
5.4.1. Hiperparámetros	10
5.4.2. Resultados	11
5.4.3. Análisis crítico	11
5.5. Modelo 2: XGBoost	11
5.5.1. Hiperparámetros	11
5.5.2. Resultados	12
5.5.3. Análisis crítico comparativo	12
6. Agrupamiento (<i>Clustering</i>)	13
6.1. Objetivo y selección de variables	13
6.2. Algoritmo y selección de k	13
6.3. Visualización con PCA	14
6.4. Interpretación de perfiles	15
7. Arquitectura y Diseño	15
7.1. Estructura de clases	15



7.2. Patrón de diseño: Pipeline	16
7.3. Diagrama UML	17
8. Reutilización del Modelo	17
9. Conclusiones	18
9.1. Hallazgos principales	18
9.2. Implicaciones macroeconómicas	19
9.3. Limitaciones	20
9.4. Trabajo futuro	20
Referencias	21



1. Introducción

1.1. ¿Cuál es el problema?

El comercio exterior de México presenta desequilibrios estructurales que se manifiestan en déficits comerciales recurrentes con ciertos socios estratégicos y superávits con otros países. Estos desequilibrios afectan directamente la balanza de pagos del país, el tipo de cambio y la competitividad de la industria nacional. Sin embargo, la magnitud, dirección y estacionalidad de estos flujos son difíciles de anticipar con métodos tradicionales, lo que limita la capacidad de las instituciones públicas y privadas para planificar con base en evidencia.

Este proyecto analiza los flujos mensuales de importaciones y exportaciones de México con sus socios comerciales durante el periodo 1993–2025, con el objetivo de identificar patrones históricos, predecir el balance comercial mensual y segmentar a los países socios según su perfil de intercambio con México.

1.2. ¿Por qué es relevante?

El comercio exterior representa uno de los pilares de la economía mexicana. De acuerdo con datos del Banco de México, las exportaciones totales de México superaron los \$593,000 millones de dólares en 2023 [1]. En ese contexto, el T-MEC concentra más del 80 % del comercio exterior mexicano, lo que hace al país particularmente vulnerable a perturbaciones en esa relación comercial. De ahí que aunque la demagogía política hable de buscar lazos comerciales fuera del continente, la realidad es que los principales socios comerciales de nuestro país estén en el continente Americano.

El contexto macroeconómico reciente refuerza la relevancia del análisis. De acuerdo con el Informe Trimestral del Banco de México (enero–marzo 2026), el PIB de México registró una contracción de 0.62 % en el primer trimestre de 2026, en un entorno de debilidad generalizada de la actividad económica [2]. Al mismo tiempo, las importaciones no petroleras alcanzaron niveles máximos históricos, mientras que las exportaciones manufactureras no automotrices mantuvieron un elevado dinamismo, impulsadas principalmente por el sector de equipo de cómputo. Este comportamiento diferenciado entre socios y sectores subraya la necesidad de herramientas analíticas que permitan identificar patrones y anticipar el balance comercial con mayor precisión.

COMENTARIO Desde años México ha sido conocido como una país manufacturero y

La relevancia del análisis radica en tres dimensiones:

- **Económica:** los desequilibrios comerciales sostenidos presionan las reservas internacionales y el tipo de cambio.
- **Industrial:** identificar los socios con mayor dinamismo permite orientar políticas de diversificación comercial.



- **Temporal:** la cobertura de 1993 a 2025 incluye eventos estructurales como el TLCAN (1994), la crisis financiera global (2008–2009), la pandemia de COVID-19 (2020) y el T-MEC (2020). Esto como parte de que los eventos sociales repercuten en el dinamismo económico de nuestro país.

1.3. ¿Qué se busca lograr?

Este proyecto tiene dos objetivos analíticos concretos y medibles:

1. **Modelado supervisado:** predecir si el balance comercial mensual de México con un país dado será superávit o déficit, incorporando el tipo de cambio MXN/USD como variable explicativa. La tarea se formula como clasificación binaria.
2. **Agrupamiento no supervisado:** segmentar los países socios en grupos homogéneos según su perfil de intercambio (volumen total, tendencia histórica y tipo de flujo predominante).

1.4. ¿Por qué este dataset?

El dataset es el registro histórico de **Comercio Exterior de México por País (1993–2025)**, disponible en datamx.io y construido a partir de registros oficiales del Banco de México [4]. Se enriqueció con el tipo de cambio MXN/USD mensual obtenido de la API del Banco de México (Serie SF43718) [3].

Su pertinencia se fundamenta en cuatro razones:

1. **Escala suficiente:** 184,392 registros mensuales.
2. **Variables relevantes:** 8 variables originales más variables derivadas (ANIO, MES, TIPO_CAMBIO, BALANCE, SUPERAVIT).
3. **Compatibilidad con ambas tareas:** permite modelado supervisado y clustering sobre los mismos datos.
4. **Fuente verificable:** licencia Creative Commons CCZero (dominio público), donde se puede corroborar que los datos son verídicos.

2. Descripción del Dataset

2.1. Dimensiones y fuente

El dataset contiene **184,392 filas** y **8 columnas originales**, con registros mensuales desde enero de 1993 hasta 2025, desagregados por país socio y tipo de flujo. Tras el enriquecimiento con el tipo de cambio de Banxico el dataset final cuenta con **12 columnas**.



2.2. Descripción de variables

Variable	Tipo	Descripción
PERIODO	Fecha	Mes y año del registro
CONTINENTE	Categórica	Continente del país socio
ID_CONTINENTE	Numérica	Código numérico del continente
PAIS	Categórica	País socio comercial
ID_PAIS	Numérica	Código numérico del país
FLUJO	Categórica	Exportaciones o Importaciones
ID_FLUJO	Numérica	Código del flujo (1 o 2)
VALOR_USD	Numérica	Valor del intercambio en USD
ANIO	Numérica	Variable derivada: año
MES	Numérica	Variable derivada: mes
TIPO_CAMBIO	Numérica	MXN/USD mensual (Banxico SF43718)
VALOR_MXN	Numérica	$VALOR_USD \times TIPO_CAMBIO$

Cuadro 1: Variables del dataset final

2.3. Limitaciones conocidas

- **Valores nominales:** VALOR_USD no está deflactado. Parte del crecimiento observado refleja inflación acumulada. Como trabajo futuro se recomienda deflactar con el INPP de EE.UU. Parece hacer un análisis de valor real y no solo nominal.
- **Granularidad:** datos agregados a nivel país-mes; no permite análisis por producto o sector económico.
- **Año incompleto:** 2025 cubre solo los meses disponibles a la fecha de extracción.
- **ID_CONTINENTE:** presenta 28,368 valores faltantes (15.4%), por lo que fue excluida del modelado, ya que nos estamos enfocando en comercio entre países, principalmente America del Norte por su relación con México.

3. Limpieza y Preparación de Datos

3.1. Valores faltantes

Únicamente ID_CONTINENTE presenta valores faltantes: 28,368 registros (15.4%). Dado que CONTINENTE contiene la misma información sin faltantes, se excluyó ID_CONTINENTE del modelado sin pérdida de información.




Figura 1: Mapa de valores faltantes. Solo ID_CONTINENTE presenta datos ausentes (15.4 %).

3.2. Registros duplicados

No se encontraron registros duplicados (0 filas, 0.0 %).

3.3. Valores atípicos

VALOR_USD presenta distribución fuertemente asimétrica. Los outliers corresponden a intercambios con EE.UU. — fenómeno real y económicamente relevante. **Decisión:** no se eliminaron; se aplicó transformación $\log_{10}$ para el modelado.




Figura 2: Boxplots de VALOR_USD en escala original y logarítmica.

3.4. Variables derivadas y enriquecimiento

- ANIO y MES: extraídas de PERIODO.
- TIPO_CAMBIO: tipo de cambio MXN/USD mensual descargado de la API del Banco de México (Serie SF43718), con cobertura enero 1993–diciembre 2025.



- VALOR_MXN: valor del intercambio convertido a pesos mexicanos.
- BALANCE: diferencia mensual exportaciones — importaciones por país.
- SUPERAVIT: variable objetivo binaria (1 = superávit, 0 = déficit).
- CONTINENTE_ENC, PAIS_ENC: codificación con `LabelEncoder`.

4. Análisis Exploratorio de Datos

4.1. Descripción general

El dataset contiene 184,392 registros mensuales de 180 países socios en 6 continentes. VALOR_USD presenta un coeficiente de variación superior al 300 %, reflejo de la enorme heterogeneidad entre socios.



4.2. Distribución de variables numéricas




Figura 3: Distribución de variables numéricas. VALOR_USD muestra asimetría extrema que se corrige con transformación logarítmica. Los registros están distribuidos uniformemente por año y mes.

La Figura 3 revela cuatro patrones: (1) VALOR_USD concentrado cerca de cero con pocos valores extremos; (2) distribución bimodal en escala logarítmica; (3) registros uniformes por año ($\approx 5,500/\text{año}$) con ligera reducción en 2025; (4) distribución mensual homogénea, descartando estacionalidad fuerte en el número de registros.



4.3. Serie de tiempo 1993–2025




Figura 4: Exportaciones vs importaciones mensuales y balance comercial mensual.

La Figura 4 permite identificar los siguientes hallazgos:

- **Tendencia creciente sostenida:** el comercio exterior pasó de \$6,000 a más de \$60,000 millones USD mensuales en tres décadas.
- **Crisis 2008–2009:** caída abrupta del $\sim 45\%$, seguida de recuperación rápida.
- **COVID-19 (2020):** contracción severa con recuperación en forma de V.
- **Balance deficitario predominante:** superávits más frecuentes a partir de 2020 con el T-MEC.

5. Modelo Supervisado



5.1. Definición de la variable objetivo

Se definió la tarea como **clasificación binaria**: predecir si el balance comercial mensual de México con un país dado será superávit ($\text{SUPERAVIT} = 1$) o déficit ($\text{SUPERAVIT} = 0$).

El dataset resultante contiene **92,196 registros país-mes** con clases balanceadas: 50.9 % superávit y 49.1 % déficit, eliminando la necesidad de técnicas de balanceo como SMOTE.

5.2. Variables de entrada

Se seleccionaron **7 features**:

- **Exportaciones**: valor mensual de exportaciones.
- **Importaciones**: valor mensual de importaciones.
- **TIPO_CAMBIO**: tipo de cambio MXN/USD del mes.
- **CONTINENTE_ENC**: región geográfica codificada.
- **PAIS_ENC**: identificador del país codificado.
- **ANIO**: tendencia temporal.
- **MES**: estacionalidad.

Se excluyeron **ID_CONTINENTE** (faltantes), **PERIODO** (reemplazado por **ANIO** y **MES**) y **BALANCE** (causa *data leakage*).

5.3. División de datos

División estratificada **80/20** con **random_state=42**: entrenamiento 73,756 registros y prueba 18,440 registros. Ambos conjuntos mantienen 50.9 % de superávit.

5.4. Modelo 1: Random Forest

5.4.1. Hiperparámetros

Búsqueda en cuadrícula (**GridSearchCV**) con 5 folds, 24 candidatos, 120 fits en total:

Hiperparámetro	Valor óptimo
n_estimators	200
max_depth	None
min_samples_split	2
min_samples_leaf	1



5.4.2. Resultados

Métrica	Valor
Accuracy	0.9893
Precision (weighted)	0.9893
Recall (weighted)	0.9893
F1-score (weighted)	0.9893
F1-score (macro)	0.9893
AUC-ROC	0.9995
Línea base	0.5091
Mejora	+48.03 pp




Figura 5: Matriz de confusión (izquierda) y curva ROC del Random Forest (AUC = 0.9995).

5.4.3. Análisis crítico

El Random Forest alcanzó 98.93 % de accuracy y AUC-ROC de 0.9995, superando la línea base en 48.03 puntos porcentuales. El alto desempeño se explica porque **Exportaciones** e **Importaciones** tienen relación directa con la variable objetivo. La incorporación del **TIPO_CAMBIO** enriquece el modelo desde una perspectiva económica, aunque su impacto marginal es limitado dado que las otras dos variables ya son casi deterministas de la clase.

5.5. Modelo 2: XGBoost

5.5.1. Hiperparámetros

Búsqueda en cuadrícula (**GridSearchCV**) con 5 folds, 24 candidatos, 120 fits en total. La métrica de optimización fue **f1_weighted**:



Hiperparámetro	Valor óptimo
n_estimators	200
max_depth	6
learning_rate	0.1
subsample	0.8

5.5.2. Resultados

Métrica	Valor
Accuracy	0.9958
Precision (weighted)	0.9958
Recall (weighted)	0.9958
F1-score (weighted)	0.9958
F1-score (macro)	0.9958
AUC-ROC	0.9999
Línea base	0.5091
Mejora	+48.67 pp




Figura 6: Matriz de confusión (izquierda) y curva ROC del modelo XGBoost (AUC = 0.9999).

5.5.3. Análisis crítico comparativo

XGBoost alcanzó 99.58% de accuracy y AUC-ROC de 0.9999, superando al Random Forest en 0.65 puntos porcentuales (98.93% vs 99.58%) y a la línea base en 48.67 puntos porcentuales.

La ventaja de XGBoost sobre Random Forest se explica por su mecanismo de *boosting*: mientras Random Forest construye árboles de forma paralela e independiente, XGBoost los construye secuencialmente, corrigiendo los errores de la iteración anterior mediante



gradiente descendente. Esto le permite capturar relaciones más sutiles entre las variables explicativas y la clase objetivo, como la interacción entre **TIPO_CAMBIO** y los flujos comerciales en periodos de alta volatilidad cambiaria.

El AUC-ROC de 0.9999 indica que el modelo distingue casi perfectamente entre superávit y déficit en todos los umbrales de clasificación posibles, lo que lo convierte en el modelo más robusto del proyecto para esta tarea.




Figura 7: Comparación de Accuracy: línea base, Random Forest y XGBoost.

6. Agrupamiento (*Clustering*)

6.1. Objetivo y selección de variables

El agrupamiento tiene como propósito segmentar los **234 países socios** de México en perfiles homogéneos de intercambio comercial. Las features del perfil por país son: **EXP_TOTAL**, **IMP_TOTAL**, **BALANCE_PROM**, **EXP_PROM**, **IMP_PROM** y **N_MESES**. Todas las variables fueron normalizadas con **StandardScaler** antes del agrupamiento.

6.2. Algoritmo y selección de k

Se utilizó **K-Means** por su eficiencia con datos numéricos continuos y su interpretabilidad. Para determinar el número óptimo de clusters se emplearon dos criterios:




Figura 8: Método del codo (izquierda) y coeficiente de silueta (derecha).

El coeficiente de silueta sugirió $k = 2$ (silueta = 0.9887), resultado dominado por el volumen atípico de Estados Unidos. Se seleccionó $k = 4$ para obtener una segmentación más informativa que distinga perfiles de alto, medio y bajo volumen comercial.

6.3. Visualización con PCA




Figura 9: Clusters de socios comerciales visualizados con PCA (varianza explicada: 100 %).



6.4. Interpretación de perfiles

Cluster	Países	Perfil interpretativo
0	227 países	Socios marginales — bajo volumen, déficit moderado. Incluye la mayoría de países de África, Oceanía y América Latina.
1	Estados Unidos	Socio estratégico dominante — volumen $60\times$ mayor que cualquier otro socio. México tiene superávit estructural gracias al T-MEC.
2	China	Gran déficit estructural — México importa $\sim \$1.5$ billones pero exporta solo \$128 mil millones. Déficit promedio de \$3,461 millones USD mensuales.
3	Alemania, Japón, Corea del Sur, Malasia, Taiwán	Socios tecnológicos deficitarios — proveedores de manufactura avanzada. México importa maquinaria y componentes electrónicos.

Cuadro 2: Perfiles interpretativos de los 4 clusters

Los resultados son consistentes con el contexto macroeconómico: el Informe Trimestral de Banxico (Q1 2026) reporta que las importaciones de uso intermedio no petroleras alcanzaron niveles máximos históricos, impulsadas principalmente por equipo de cómputo y sus partes [2] — precisamente los sectores que dominan los Clusters 2 y 3.

7. Arquitectura y Diseño

7.1. Estructura de clases

El proyecto está organizado en 7 clases Python con responsabilidades bien definidas, siguiendo principios de encapsulamiento y separación de responsabilidades:



Clase	Responsabilidad
DataLoader	Carga y enriquecimiento con tipo de cambio
EDA	Calidad de datos y estadísticas descriptivas
EDAVisualizaciones	Histogramas, series de tiempo y correlaciones
Preprocessor	Encoding, normalización y división 80/20
ModelTrainer	Entrenamiento y evaluación Random Forest
ModelTrainerXGBoost	Entrenamiento y evaluación XGBoost
Clustering	K-Means y visualización de perfiles
Pipeline	Orquestación del flujo completo
Stage	Etapas individuales del pipeline

7.2. Patrón de diseño: Pipeline

Se implementó el **patrón Pipeline**, el más adecuado para este proyecto porque el procesamiento ocurre en etapas secuenciales bien definidas y dependientes entre sí:

DataLoader → EDA → EDAVisualizaciones → Preprocessor → ModelTrainer →
Clustering

Cada etapa está encapsulada en un objeto **Stage** con su nombre, descripción y función ejecutable. El objeto **Pipeline** orquesta la ejecución secuencial pasando un contexto compartido entre etapas. Esto facilita la depuración (permite ejecutar desde cualquier etapa con `-desde N`) y el mantenimiento.



7.3. Diagrama UML




Figura 10: Diagrama UML de la arquitectura del proyecto.

8. Reutilización del Modelo

El modelo entrenado fue serializado con `joblib` en `models/random_forest.joblib`. Para demostrar su reutilización independiente del entrenamiento, se implementó el método `demo_prediccion()` en la clase `Pipeline`.

Ejemplo de predicción — escenario México–China, enero 2025:

```
1 import joblib
2 import pandas as pd
3
4 # Cargar modelo y transformadores sin re-entrenar
5 modelo = joblib.load('models/random_forest.joblib')
6 scaler = joblib.load('models/scaler.joblib')
7 le_cont = joblib.load('models/le_continente.joblib')
8 le_pais = joblib.load('models/le_pais.joblib')
9
10 # Datos nuevos
11 nuevos_datos = pd.DataFrame({
12     'Exportaciones': [500_000_000],
13     'Importaciones': [8_000_000_000],
14     'TIPO_CAMBIO': [17.15],
```



```
15     'CONTINENTE_ENC': [le_cont.transform(['Asia'])[0]],
16     'PAIS_ENC':       [le_pais.transform(['China'])[0]],
17     'ANIO':           [2025],
18     'MES':             [1]
19 })
20
21 datos_scaled = scaler.transform(nuevos_datos)
22 prediccion   = modelo.predict(datos_scaled)
23 probabilidad = modelo.predict_proba(datos_scaled)[0]
24 # Resultado: DEFICIT (99% probabilidad)
```

El modelo predijo **DÉFICIT** con 99% de probabilidad para el escenario México–China, resultado coherente con el Cluster 2 identificado en el agrupamiento (gran déficit estructural).

9. Conclusiones

9.1. Hallazgos principales

1. **El comercio exterior mexicano creció 10 veces en 32 años**, pasando de aproximadamente \$6,000 millones USD mensuales en 1993 a más de \$60,000 millones en 2025, con choques claramente identificables en 2009 y 2020.
2. **El balance comercial es predominantemente deficitario**, aunque con tendencia hacia superávits más frecuentes desde 2020 con la entrada en vigor del T-MEC. Esto es consistente con lo reportado por el Banco de México, cuyo Informe Trimestral (enero–marzo 2026) documenta un déficit en cuenta corriente de \$15,878 millones USD en el primer trimestre de 2026 [2].
3. **Random Forest y XGBoost alcanzaron accuracy superior al 98 %**, superando la línea base en más de 48 puntos porcentuales. XGBoost obtuvo 99.58 % frente al 98.93 % del Random Forest, siendo seleccionado como modelo final.
4. **El clustering reveló 4 perfiles estratégicos** que sintetizan la estructura del comercio exterior mexicano: EE.UU. como socio dominante con superávit estructural, China como fuente de déficit masivo (-\$3,461M USD/mes promedio), socios tecnológicos deficitarios (Alemania, Japón, Corea del Sur, Malasia, Taiwán) y 227 socios marginales.
5. **La demostración en vivo confirmó la consistencia** entre el modelo supervisado y el clustering: las predicciones por cluster reprodujeron exactamente los perfiles identificados — superávit con EE.UU. (81.5 % de probabilidad) y déficit con China y Japón (99 % y 98 % respectivamente).



9.2. Implicaciones macroeconómicas

Una pregunta natural que surge del análisis es: **¿puede este modelo usarse para anticipar si la balanza comercial general de México será superavitaria o deficitaria?**

La respuesta es **parcialmente afirmativa**. El modelo predice el balance por par países; dado que Estados Unidos concentra más del 80 % del comercio exterior mexicano, las predicciones sobre ese socio tienen un peso determinante sobre el balance agregado. Si el modelo anticipa déficit con EE.UU. en un mes dado, es muy probable que la balanza general también sea deficitaria ese mes.

Esta capacidad predictiva tiene implicaciones macroeconómicas directas:

- **Reservas internacionales:** un déficit comercial sostenido reduce las reservas internacionales del Banco de México porque el país necesita más dólares para cubrir el exceso de importaciones sobre exportaciones. Las reservas internacionales de México se situaron en aproximadamente \$226,000 millones USD a inicios de 2026, y su trayectoria está directamente vinculada al comportamiento de la balanza comercial.
- **Tipo de cambio MXN/USD:** el déficit comercial genera mayor demanda de dólares en el mercado cambiario, lo que ejerce presión depreciatoria sobre el peso mexicano. Este es precisamente el mecanismo por el cual el tipo de cambio pasó de \$3.10 a \$24.27 MXN/USD entre 1993 y 2025 — periodo cubierto por este análisis. La incorporación del tipo de cambio como variable explicativa en el modelo captura parte de esta dinámica.
- **Política monetaria:** el Banco de México monitorea la balanza comercial como uno de los indicadores de presión sobre el tipo de cambio. Cuando el déficit se amplía sostenidamente, Banxico puede optar por aumentar la tasa de interés de referencia para hacer más atractivos los activos en pesos y frenar la depreciación, como ha ocurrido en varios episodios del periodo analizado.
- **Decisiones de inversión:** los inversionistas institucionales y las calificadoras de riesgo soberano utilizan la balanza comercial como indicador de la vulnerabilidad externa de México. Un déficit creciente puede traducirse en salidas de capital, mayor costo de financiamiento externo y presión adicional sobre el tipo de cambio — creando un ciclo retroalimentado que este modelo ayuda a anticipar.

En síntesis, este proyecto demuestra que las herramientas de minería de datos — históricamente asociadas a problemas de marketing o tecnología — tienen aplicaciones directas y de alto valor en el análisis de política económica. La combinación de un modelo supervisado de alta precisión con una segmentación no supervisada de socios comerciales ofrece un marco analítico que complementa los métodos econométricos tradicionales con los que se forman los economistas, aportando capacidad predictiva, escalabilidad y visualización de patrones difíciles de detectar con regresión lineal.



9.3. Limitaciones

- **Valores nominales:** VALOR_USD no está deflactado por inflación. Parte del crecimiento observado refleja inflación acumulada y no necesariamente mayor volumen real de comercio.
- **Relación casi determinista:** el alto accuracy del modelo ($>98\%$) refleja que Exportaciones e Importaciones tienen una relación directa con la variable objetivo. El modelo aprende esencialmente la fórmula del balance, lo que lo hace muy preciso pero limita su valor predictivo cuando solo se dispone de variables indirectas.
- **Granularidad:** el dataset agrega por país-mes sin desagregación por producto o sector, lo que impide analizar la composición del comercio.
- **Balance agregado:** el modelo predice por par país-mes, no el balance nacional total. Para estimar el agregado se requeriría ponderar las predicciones por el peso de cada socio en el comercio total.

9.4. Trabajo futuro

- **Deflactación:** incorporar el Índice Nacional de Precios al Productor (INPP) para convertir VALOR_USD a valores reales, eliminando el efecto inflacionario de 32 años de datos.
- **Clustering por fracción arancelaria:** aplicar agrupamiento a nivel de código TIGIE (fracción arancelaria a 8 dígitos), disponible en la Balanza Comercial de Mercancías de México del SAT/INEGI. Este análisis permitiría confirmar empíricamente hipótesis como el dominio de China en circuitos integrados y semiconductores, la especialización de México en manufactura de ensamble automotriz y electrónico, o la dependencia de insumos agrícolas de EE.UU. — revelando con precisión el perfil productivo de México en la cadena de valor global.
- **Variables macroeconómicas adicionales:** incorporar PIB de socios comerciales, aranceles vigentes (relevante en el contexto de las tensiones comerciales 2025–2026), e índices de confianza empresarial como los reportados por Banxico en su Informe Trimestral.
- **Predicción del balance agregado:** extender el modelo para predecir el valor numérico del balance comercial total de México (regresión) con horizonte de 6–12 meses, lo que permitiría anticipar presiones sobre las reservas internacionales y el tipo de cambio con mayor antelación.
- **Series de tiempo:** aplicar modelos ARIMA o LSTM para capturar la dinámica temporal del balance comercial, incorporando la estacionalidad y las tendencias de largo plazo identificadas en el EDA.



Referencias

Referencias

- [1] Banco de México. (2024). *Estadísticas de Balanza de Pagos*. Recuperado de <https://www.banxico.org.mx/>
- [2] Banco de México. (2026). *Informe Trimestral Enero–Marzo 2026*. Información de acceso público. <https://www.banxico.org.mx/publicaciones-y-prensa/informes-trimestrales/>
- [3] Banco de México. (2025). *Sistema de Información Económica (SIE) — API REST. Serie SF43718: Tipo de cambio interbancario MXN/USD*. <https://www.banxico.org.mx/SieAPIRest/service/v1/>
- [4] Codeando México. (2025). *Comercio Exterior de México por País (1993–2025)* [Conjunto de datos]. datamx.io. <https://datamx.io/es/dataset/comercio-exterior-de-mexico-por-pais-1993-2025>
- [5] Secretaría de Economía. (2024). *DataMéxico — Visualizador de Comercio Exterior*. Gobierno de México. <https://www.economia.gob.mx/datamexico/es/vizbuilder>
- [6] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- [7] Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD*, 785–794. <https://doi.org/10.1145/2939672.2939785>
- [8] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- [9] MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. *Proceedings of the 5th Berkeley Symposium*, 1(14), 281–297.